

## Лекция 6. Тензорные разложения

М. В. Рахуба

28 февраля 2024 г.

В этом курсе мы в основном работаем с матрицами — двумерными массивами, но данные могут иметь и бóльшую размерность. Тензором размерности  $d$  будем называть многомерный массив:

$$A = \{a_{i_1 \dots i_d}\}_{i_1, \dots, i_d=1}^{n_1, \dots, n_d} \in \mathbb{R}^{n_1 \times \dots \times n_d}.$$

При  $n_1 = \dots = n_d = n$  хранение такого массива в компьютере требует  $n^d$  ячеек памяти, что при больших  $d$  может оказаться невозможным из-за экспоненциального роста  $n^d$  с размерностью  $d$ . Например,  $2^{300}$  намного больше оценки числа атомов во Вселенной. Это проявление так называемого *проклятия размерности*. Поэтому в случае с тензорами высокой размерности нас будут интересовать способы их представления с помощью небольшого числа параметров или другими словами нас будет интересовать сжатие тензоров. В этом нам помогут тензорные разложения, которые по сути являются обобщением скелетного разложения матриц на тензоры размерности  $d \geq 3$ .

### 1 Кронекерово произведение и векторизация

Свойства тензоров и тензорных разложений часто удается свести к матричному случаю. Чтобы научиться такие матрицы выписывать через элементы тензорных разложений, нам понадобятся две новые операции: кронекерово произведение и векторизация. Отметим также, что эти операции оказываются полезными и в других случаях, не связанных с тензорными разложениями. Например, при работе с изображениями.

#### 1.1 Кронекерово произведение

**Определение 1.** Кронекеровым произведением матриц  $A \in \mathbb{C}^{m \times n}$  и  $B \in \mathbb{C}^{p \times q}$  называется:

$$A \otimes B = \begin{bmatrix} a_{11}B & \dots & a_{1n}B \\ \vdots & \ddots & \vdots \\ a_{m1}B & \dots & a_{mn}B \end{bmatrix} \in \mathbb{C}^{mp \times nq}.$$

Обратим внимание, что Кронекерово произведение определено для матриц любых размеров и содержит в себе всевозможные попарные произведения элементов матриц  $A$  и  $B$ .

Обращаем внимание, что такое определение тензора нередко можно встретить в публикациях по прикладной математике или глубинному обучению. Однако классически под тензором понимается более общий объект.

На практике не часто встречаются тензоры, которые можно сжать с помощью тензорных разложений без потери качества. Поэтому нас будет также интересовать вопрос построения приближений с контролируемой ошибкой (по аналогии как мы это делали для матриц через SVD и теорему Эккарта-Янга-Мирского).

**Пример 1.**

$$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \otimes \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \end{bmatrix}, \quad \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \otimes \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{bmatrix}.$$

**Утверждение 1.** Пусть  $A, B, C, D$  — некоторые комплекснозначные матрицы. Тогда выполняются следующие свойства:

## 1. Ассоциативность:

$$(A \otimes B) \otimes C = A \otimes (B \otimes C).$$

## 2. Дистрибутивность:

$$(A + B) \otimes C = A \otimes C + B \otimes C,$$

$$A \otimes (B + C) = A \otimes B + A \otimes C.$$

3.  $(A \otimes B)^\top = A^\top \otimes B^\top$  и  $(A \otimes B)^* = A^* \otimes B^*$ .4.  $A \otimes B = (A \otimes I)(I \otimes B) = (I \otimes B)(A \otimes I)$ .5.  $(AB) \otimes (CD) = (A \otimes C)(B \otimes D)$ .6.  $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$  для обратимых  $A, B$ .

Формально свойство 4 записывается как  $A \otimes B = (A \otimes I_p)(I_n \otimes B) = (I_m \otimes B)(A \otimes I_q)$ , где  $A \in \mathbb{C}^{m \times n}$ ,  $B \in \mathbb{C}^{p \times q}$ , но для удобства мы будем позволять себе опускать размеры матриц  $I$ , так как в большинстве случаев они однозначно определяются из контекста.

Обратите особое внимание на свойство 5, которое будет нам неоднократно встречаться в дальнейшем. Также свойства 4 и 6 элементарно из него следуют.

**Доказательство.** Первые три свойства очевидно следуют из свойств транспонирования, комплексного сопряжения и умножения матриц, и их справедливость можно показать, явно расписав  $ij$ -ый элемент каждой итоговой матрицы. Здесь же докажем остальные.

## 4. Пользуясь правилом блочного умножения матриц:

$$\begin{aligned} (A \otimes I)(I \otimes B) &= \begin{bmatrix} a_{11}I & \dots & a_{1n}I \\ \vdots & \ddots & \vdots \\ a_{m1}I & \dots & a_{mn}I \end{bmatrix} \begin{bmatrix} B & & \\ & \ddots & \\ & & B \end{bmatrix} = \\ &= \begin{bmatrix} a_{11}B & \dots & a_{1n}B \\ \vdots & \ddots & \vdots \\ a_{m1}B & \dots & a_{mn}B \end{bmatrix} = A \otimes B. \end{aligned}$$

Аналогично показывается  $(I \otimes B)(A \otimes I) = A \otimes B$ .

## 5. Используя свойство 4 имеем:

$$\begin{aligned} (A \otimes C)(B \otimes D) &= (A \otimes I)(I \otimes C)(B \otimes I)(I \otimes D) = \\ &= (A \otimes I)(B \otimes I)(I \otimes C)(I \otimes D) = \\ &= ((AB) \otimes I)(I \otimes (CD)), \end{aligned}$$

где последнее равенство следует из  $(A \otimes I)(B \otimes I) = (AB) \otimes I$  и  $(I \otimes C)(I \otimes D) = I \otimes (CD)$ . Действительно,

$$\begin{aligned} (I \otimes C)(I \otimes D) &= \begin{bmatrix} C & & \\ & \ddots & \\ & & C \end{bmatrix} \begin{bmatrix} D & & \\ & \ddots & \\ & & D \end{bmatrix} = \\ &= \begin{bmatrix} CD & & \\ & \ddots & \\ & & CD \end{bmatrix} = I \otimes CD. \end{aligned}$$

Свойство  $(A \otimes I)(B \otimes I) = (AB) \otimes I$  проверьте самостоятельно.

6. Пусть матрицы  $A \in \mathbb{C}^{m \times m}$ ,  $B \in \mathbb{C}^{n \times n}$  обратимы, тогда:

$$(A \otimes B)(A^{-1} \otimes B^{-1}) = (AA^{-1}) \otimes (BB^{-1}) = I_m \otimes I_n = I_{mn},$$

а значит  $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$ .

□

**Замечание 1.** Кронекерово произведение не является коммутативным. Смотри пример 1.

На этом все свойства кронекерова произведения матриц, конечно, не заканчиваются. Мы познакомились только с самыми базовыми из них. Многие другие свойства можно получить используя свойство 5 из Утверждения 1 и применяя его к некоторым матричным разложениям. Например, несложно убедиться, что сингулярные числа  $A \otimes B$  являются всевозможными попарными произведениями сингулярных чисел  $A$  и  $B$ . Отсюда сразу следует, что

$$\|A \otimes B\|_2 = \|A\|_2 \|B\|_2.$$

## 1.2 Векторизация

**Определение 2.** Определим  $\text{vec}(\cdot): \mathbb{C}^{m \times n} \rightarrow \mathbb{C}^{mn}$  как векторизацию матрицы по столбцам, то есть:

$$\text{vec} \left( \begin{bmatrix} a_1 & a_2 & \dots & a_n \end{bmatrix} \right) = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}, \quad \text{где } a_k \in \mathbb{C}^m.$$

Мы не зря вводим векторизацию вместе с кронекеровым произведением. Покажем, как эти две операции связаны связаны друг с другом.

**Утверждение 2.** Пусть определено произведение  $AXB$ . Тогда:

$$\text{vec}(AXB) = (B^\top \otimes A) \text{vec}(X).$$

*Доказательство.* Сначала заметим, что

$$\text{vec}(uv^\top) = \text{vec}\left(\begin{bmatrix} v_1u & v_2u & \dots & v_nu \end{bmatrix}\right) = \begin{bmatrix} v_1u \\ v_2u \\ \vdots \\ v_nu \end{bmatrix} = v \otimes u.$$

Пусть  $X = uv^\top$ , тогда из выписанного выше выражения и свойства 5 Утверждения 1 получим:

$$\begin{aligned} \text{vec}(A(uv^\top)B) &= \text{vec}((Au)(B^\top v)^\top) = (B^\top v) \otimes (Au) = \\ &= (B^\top \otimes A)(v \otimes u) = (B^\top \otimes A) \text{vec}(uv^\top) = (B^\top \otimes A) \text{vec}(X). \end{aligned}$$

Произвольный же  $X$  является суммой матриц ранга 1, поэтому для него данное утверждение тоже справедливо в силу линейности  $\text{vec}(\cdot)$ .  $\square$

## 2 Тензорные разложения

В этом разделе мы поговорим о двух разложениях, которые обобщают скелетное разложение матриц на случай тензоров размерности больше 2. Эти разложения называются каноническим разложением и разложением Таккера. В отличие от разложения Таккера, каноническое разложение по своим свойствам будет заметно отличаться от скелетного матричного разложения. Как мы увидим, у каждого из разложений будут свои достоинства и недостатки при использовании в приложениях. Также отметим, что существует и множество других тензорных разложений, которые остаются за рамками настоящего курса, но представляют значительный интерес с практической точки зрения.

### 2.1 Каноническое разложение

**Определение 3.** Пусть  $A \in \mathbb{R}^{n_1 \times \dots \times n_d}$ ,  $B \in \mathbb{R}^{m_1 \times \dots \times m_D}$  — тензоры размерностей  $d$  и  $D$  соответственно. Тогда их тензорным произведением назовем тензор  $A \circ B \in \mathbb{R}^{n_1 \times \dots \times n_d \times m_1 \times \dots \times m_D}$  размерности  $(d + D)$  с элементами:

$$(A \circ B)_{i_1 \dots i_d j_1 \dots j_D} = a_{i_1 \dots i_d} b_{j_1 \dots j_D}.$$

Посмотрим, как мы можем использовать тензорное произведение для записи скелетного разложения матриц. Во-первых,

Иногда тензорное произведение  $\circ$  обозначают как  $\otimes$ , но в нашем курсе  $\otimes$  уже занято под кронекерово произведение.

заметим, что любая матрица ранга 1 имеет вид  $A = uv^\top$  или  $a_{ij} = u_i v_j$  в индексной записи. Отсюда, используя только что введенное определение, получим:

$$A = uv^\top = u \circ v.$$

По аналогии можно определить трехмерный тензор ранга 1, как ненулевой тензор с элементами  $a_{ijk} = u_i v_j w_k$ . С использованием тензорного произведения получим:

$$A = u \circ v \circ w.$$

Обсудим теперь случай ранга  $r$ . Вспомним, что любая матрица ранга  $r$  записывается с помощью матриц  $U = [u_1, \dots, u_r]$  и  $V = [v_1, \dots, v_r]$ :

$$A = UV^\top = u_1 \circ v_1 + \dots + u_r \circ v_r, \quad (1)$$

причем ранг матрицы есть минимально возможное число слагаемых в (1). Обобщим это разложение на случай трехмерных массивов (обобщение для массивов размерности  $d > 3$  делается аналогично).

**Определение 4.** Каноническим разложением  $A \in \mathbb{R}^{n_1 \times n_2 \times n_3}$  назовем разложение вида:

$$A = \sum_{\alpha=1}^r u_\alpha \circ v_\alpha \circ w_\alpha.$$

Матрицы  $U = [u_1, \dots, u_r]$ ,  $V = [v_1, \dots, v_r]$  и  $W = [w_1, \dots, w_r]$  назовем каноническими факторами, а минимально возможное  $r$  — каноническим рангом. Для краткости также будем использовать следующее обозначение:

$$A = \llbracket U, V, W \rrbracket.$$

Теперь обсудим, что мы можем сказать про существование и единственность канонического разложения, и возможно ли найти наилучшее приближение тензора тензором меньшего канонического ранга. А также сравним эти свойства со скелетным матричным разложением. Подробнее про свойства канонического разложения можно ознакомиться в <sup>1</sup>.

**Замечание 2 (Существование).** Каноническое разложение существует для любого тензора, причем  $r \leq n_1 n_2 n_3$ , так как

$$A = \sum_{i=1}^{n_1} \sum_{j=1}^{n_2} \sum_{k=1}^{n_3} a_{ijk} e_i \circ e_j \circ e_k, \quad (2)$$

Обратите внимание, что мы можем не расставлять скобки в силу ассоциативности тензорного произведения.

<sup>1</sup>Tamara G Kolda and Brett W Bader. Tensor decompositions and applications. SIAM review, 51(3):455–500, 2009

где  $e_i$  — векторы стандартного базиса. Более тонкое наблюдение заключается в том, что канонический ранг удовлетворяет  $r \leq \min(n_1 n_2, n_1 n_3, n_2 n_3)$  (проверьте). Таким образом, как и в случае со скелетным разложением, оно всегда существует.

**Замечание 3** (Единственность). Скелетное разложение для матриц не является единственным. Действительно, для произвольной невырожденной  $S$ :

$$UV^\top = (US)(S^{-1}V^\top).$$

Оказывается, что при некоторых предположениях на тензор, каноническое разложение может быть единственным с точностью до перестановки слагаемых и шкалирования векторов. В случае с матрицами это бы означало, что  $S$  могло бы быть только произведением матрицы перестановки и диагональной матрицы, а не произвольной невырожденной матрицей.

**Замечание 4** (Существование наилучшего приближения). Согласно теореме Экарта-Янга-Мирского для любой ненулевой матрицы всегда найдется наилучшее приближение (в смысле унитарно-инвариантной нормы) матрицей меньшего ранга. Для канонического разложения это уже не так. Множество тензоров ранга  $\leq r$  не является замкнутым, а значит можно, например, построить последовательность тензоров  $\{A_n\}$ :  $\text{rank } A_n = 2$ , которая сходится к тензору  $A$ :  $\text{rank } A = 3$ . Это может оказаться чревато разными неприятными эффектами при попытке построить наилучшее приближение заданного ранга с помощью численных алгоритмов. Подробнее об этом будет рассказано на семинаре.

Таким образом, каноническое разложение обладает как некоторыми свойствами, которые могут оказаться полезными на практике, например, единственность, так и неприятными свойствами, как проблемы с построением наилучшего приближения заданного ранга. Далее мы обсудим разложение Таккера, которое по свойствам больше напоминает матричный случай.

## 2.2 Разложение Таккера

Для следующей попытки обобщить скелетное разложение воспользуемся следующей его записью:

$$A = UGV^\top = \sum_{\alpha, \beta=1}^{r,r} g_{\alpha\beta} u_\alpha \circ v_\beta,$$

для некоторой  $G \in \mathbb{R}^{r \times r}$ . Для матриц нет разницы, в каком виде выбирать скелетное разложение, так как один его вид сводится к другому:  $A = \tilde{U}V^\top$ , где  $\tilde{U} = UG$ . Для тензоров размерности  $d \geq 3$  различия уже будут.

**Определение 5.** Разложением Таккера тензора  $A \in \mathbb{R}^{n_1 \times n_2 \times n_3}$  называют разложение вида:

$$A = \sum_{\alpha=1}^{r_1} \sum_{\beta=1}^{r_2} \sum_{\gamma=1}^{r_3} g_{\alpha\beta\gamma} u_\alpha \circ v_\beta \circ w_\gamma,$$

где тензор

$$G = \{g_{\alpha\beta\gamma}\}_{\alpha,\beta,\gamma=1}^{r_1,r_2,r_3} \in \mathbb{R}^{r_1 \times r_2 \times r_3},$$

называется таккеровским ядром, а матрицы

$$\begin{aligned} U &= [u_1, \dots, u_{r_1}] \in \mathbb{R}^{n_1 \times r_1}, \\ V &= [v_1, \dots, v_{r_2}] \in \mathbb{R}^{n_2 \times r_2}, \\ W &= [w_1, \dots, w_{r_3}] \in \mathbb{R}^{n_3 \times r_3}. \end{aligned}$$

называются таккеровскими факторами. Кортеж чисел

$$\text{mlrank}(A) = (r_1, r_2, r_3),$$


где каждое  $r_i$  является минимально возможным для  $A$  значением, называется мультилинейным или таккеровским рангом. Обозначать разложение Таккера будем следующим образом:

$$A = \llbracket G; U, V, W \rrbracket.$$

Существование разложения Таккера для любого тензора с рангами  $(n_1, n_2, n_3)$  также следует из (2).

Оценим, насколько разложение Таккера экономит память для случая  $n_1 = n_2 = n_3 = n$  и  $r_1 = r_2 = r_3 = r$ , если  $r \ll n$ .

Дальше мы узнаем, что минимально возможные значения  $r_i$  для заданного тензора  $A$  достигаются одновременно, а значит данное нами определение мультилинейного ранга является корректным.



Каждый из факторов Таккера займет в памяти  $nr$  ячеек, ядро Таккера – еще  $r^3$ , и все это вместо  $n^3$  для хранения исходного тензора  $A$ :

$$\frac{\text{mem}(\llbracket G; U, V, W \rrbracket)}{\text{mem}(A)} = \frac{r^3 + 3nr}{n^3} = \left(\frac{r}{n}\right)^3 + \frac{3}{r} \left(\frac{r}{n}\right)^2 \ll 1.$$

**Векторизация тензора.** Чтобы лучше понять, как устроено разложение Таккера, нам необходимо свести его к известным нам объектам, а именно к векторам и матрицам. По аналогии с матричным случаем определим векторизацию тензора как применение функции `reshape` с использованием аргумента `order='f'` (то есть по столбцам в порядке увеличения индексов слева направо). Начнем с обобщения Утверждения 2.

**Утверждение 3.** Пусть определено  $\llbracket G; U, V, W \rrbracket$ . Тогда:

$$\text{vec}(\llbracket G; U, V, W \rrbracket) = (W \otimes V \otimes U) \text{vec}(G).$$

**Доказательство.** Утверждение доказывается аналогично Утверждению 2. Необходимо только проверить, что

$$\text{vec}(u \circ v \circ w) = w \otimes v \otimes u$$

и что

$$\llbracket (a \circ b \circ c); U, V, W \rrbracket = (Ua) \circ (Vb) \circ (Wc).$$







Далее пользуемся (2) для  $G$ . □

**Матрицизации тензора.** Таким образом, мы нашли, через какую матрицу соотносятся векторизации тензора  $A$  и тензора  $G$ . Теперь попробуем понять, как связаны их матрицизации (переупорядочивание элементов в матрицу). Дадим сначала определение одного из видов превращения тензора в матрицу — так называемую развертку по  $k$ -й моде.

**Определение 6.** Разверткой по  $k$ -моду тензора  $A \in \mathbb{R}^{n_1 \times \dots \times n_d}$  назовем матрицу  $A_{(k)} \in \mathbb{R}^{n_k \times (n_1 \dots n_d)/n_k}$ , столбцы которой являются  $a_{i_1, \dots, i_{k-1}, :, i_{k+1}, \dots, i_d} \in \mathbb{R}^{n_k}$ , расположенными в “фортрановском” порядке (увеличение индексов слева направо).

Визуализируем, как выглядят развертки для трехмерного массива  $A \in \mathbb{R}^{3 \times 3 \times 3}$ :





Несложно также записать, как будет выглядеть развертка по  $k$ -й моде ( $k \in \{1, 2, 3\}$ ) на Python:

```
order = list(range(3))
order[0], order[k-1] = order[k-1], order[0]
Ak = np.transpose(A, order)
Ak = np.reshape(Ak, (nk, (n1*n2*n3)/nk), order='f')
```

Запишем теперь формулы для матрицизаций разложения Таккера тензора  $A$ .

**Утверждение 4.**  $A = \llbracket G; U, V, W \rrbracket$  эквивалентно любой из:

$$\begin{aligned} A_{(1)} &= UG_{(1)}(W \otimes V)^\top, \\ A_{(2)} &= VG_{(2)}(W \otimes U)^\top, \\ A_{(3)} &= WG_{(3)}(V \otimes U)^\top. \end{aligned}$$

*Доказательство.* Докажем формулу для  $A_{(1)}$ . Остальные доказываются аналогично. Ключевым наблюдением является тот факт, что  $\text{vec}(A) = \text{vec}(A_{(1)})$ . Отсюда, используя утверждения 2 и 3 получим:

$$\begin{aligned} \text{vec}(A_{(1)}) &= \text{vec}(A) = \\ &= (W \otimes V \otimes U) \text{vec}(G) = (W \otimes V \otimes U) \text{vec}(G_{(1)}) = \\ &= ((W \otimes V) \otimes U) \text{vec}(G_{(1)}) = \text{vec}(UG_{(1)}(W \otimes V)^\top), \end{aligned}$$

а значит  $A_{(1)} = UG_{(1)}(W \otimes V)^\top$ .  $\square$

Теперь мы готовы сформулировать теорему, которая проясняет наше определение мультилинейного ранга и объясняет, как этот ранг можно свести к хорошо знакомому нам матричному рангу.

**Теорема 1.** Для мультилинейного ранга тензора  $A \in \mathbb{R}^{n_1 \times n_2 \times n_3}$  справедливо:

$$\text{mlrank}(A) = (\text{rank}(A_{(1)}), \text{rank}(A_{(2)}), \text{rank}(A_{(3)})),$$

причем разложение Таккера со значением  $(r_1, r_2, r_3) = \text{mlrank}(A)$  существует.

*Доказательство.* Пусть дано разложение Таккера с  $G \in \mathbb{R}^{r_1 \times r_2 \times r_3}$  с некоторыми  $r_1, r_2, r_3$ . Заметим, что

$$A_{(1)} = \underbrace{U}_{n_1 \times r_1} \underbrace{G_{(1)}(W \otimes V)^\top}_{r_1 \times n_2 n_3},$$

то есть число  $r_1$  не может быть меньше ранга  $A_{(1)}$ . Покажем, как уменьшить  $r_1$  в точности до  $\text{rank}(A_{(1)})$ . Пусть  $A_{(1)} = U_1 \Sigma_1 V_1^\top$  — компактное SVD матрицы  $A_{(1)}$ , то есть  $U_1 \in \mathbb{R}^{n_1 \times \text{rank}(A_{(1)})}$ . Тогда:

$$A_{(1)} = U_1 U_1^\top A_{(1)} = U_1 \underbrace{U_1^\top U G_{(1)}}_{\tilde{G}_{(1)}} (W \otimes V)^\top = U_1 \tilde{G}_{(1)} (W \otimes V)^\top,$$

что по Утверждению 4 эквивалентно

$$A = \llbracket \tilde{G}; U_1, V, W \rrbracket, \quad \tilde{G} \in \mathbb{R}^{\text{rank}(A_{(1)}) \times r_2 \times r_3}.$$

Аналогично сводим  $r_2 \rightarrow \text{rank}(A_{(2)})$  и  $r_3 \rightarrow \text{rank}(A_{(3)})$ . То есть мы явно построили разложение с рангами разверток.  $\square$

Таким образом, компоненты мультилинейного ранга есть размерности пространств натянутых соответственно на столбцы, строки и волокна (по 3-й размерности). Обратите внимание, что в случае  $d \geq 3$  и  $n_1, n_2, n_3 > 1$  эти размерности не обязаны совпадать, тогда так как при  $d = 2$  нам хорошо известно, что столбцовый и строчные ранги равны друг другу.

### 2.3 HOSVD алгоритм (без доказательства)

Обсудим теперь HOSVD (higher-order SVD)<sup>2</sup> — один из известных алгоритмов построения малорангового приближения в виде разложения Таккера. Для этого нам понадобится ввести норму на  $\mathbb{R}^{n_1 \times n_2 \times n_3}$ . Простейшим выбором является обобщение понятия нормы Фробениуса с матричного случая:

$$\|A\|_F = \sqrt{\sum_{i,j,k} |a_{ijk}|^2} \equiv \|\text{vec}(A)\|_2.$$

Теперь сформулируем сам алгоритм.

1. С помощью SVD от  $A_{(k)}$  для  $k = 1, 2, 3$ , найдем  $U_k \in \mathbb{R}^{n_k \times r_k}$  — первые  $r_k$  левых сингулярных векторов  $A_{(k)}$ , причем:

$$\|A_{(k)} - U_k U_k^\top A_{(k)}\|_F \leq \varepsilon_k \|A_{(k)}\|_F.$$

2. Вычислим ядро по формуле:

$$G = \llbracket A; U_1^\top, U_2^\top, U_3^\top \rrbracket.$$

3. Положим  $A_{\text{HOSVD}} = \llbracket G; U_1, U_2, U_3 \rrbracket$ .

Можно показать, что в таком случае:

$$\|A - A_{\text{HOSVD}}\|_F \leq \sqrt{\varepsilon_1^2 + \varepsilon_2^2 + \varepsilon_3^2} \|A\|_F.$$

К сожалению, в отличие от двумерного случая, нам оказывается недоступным построение оптимального приближения, однако можно показать, что HOSVD алгоритм выдает квазиоптимальное приближение, а именно:

$$\|A - A_{\text{HOSVD}}\|_F \leq \sqrt{3} \inf_{\text{mlrank}(B) \leq (r_1, r_2, r_3)} \|A - B\|_F.$$

## 3 Другие тензорные разложения

Разложения Таккера и каноническое разложения несложно записать и для размерности  $d > 3$ . Например, разложение Так-

<sup>2</sup> Lieven De Lathauwer, Bart De Moor, and Joos Vandewalle. A multilinear singular value decomposition. *SIAM journal on Matrix Analysis and Applications*, 21(4):1253–1278, 2000

Алгоритм можно запускать как по заданным значениям  $r_1, r_2, r_3$ , из которых уже находим  $\varepsilon_1, \varepsilon_2, \varepsilon_3$ , а можно сначала зафиксировать  $\varepsilon_1, \varepsilon_2, \varepsilon_3 > 0$ , и по ним подобрать значения  $r_1, r_2, r_3$ .

Под  $\text{mlrank}(B) \leq (r_1, r_2, r_3)$  подразумевается покомпонентное сравнение.

Результат также обобщается и на многомерный случай с константой квазиоптимальности  $\sqrt{d}$  вместо  $\sqrt{3}$ .

кера тензора  $A \in \mathbb{R}^{n_1 \times \dots \times n_d}$  будет иметь вид:

$$A = \sum_{\alpha_1=1}^{r_1} \dots \sum_{\alpha_d=1}^{r_d} g_{\alpha_1 \dots \alpha_d} u_{\alpha_1}^{(1)} \circ \dots \circ u_{\alpha_d}^{(d)}.$$

Проблема заключается в том, что нам необходимо хранить таккеровское ядро  $G \in \mathbb{R}^{r_1 \times \dots \times r_d}$ , которое имеет такую же размерность, как и исходной тензор  $A$ . Значит даже при  $r_k \ll n_k$ , оно все еще подвержено проклятию размерности и при больших  $d$  оказывается непрактичным. Это мотивировало разработку и использование альтернативных тензорных разложений, для которых бы существовали надежные алгоритмы на основе сингулярного разложения, но которые при этом не были бы подвержены проклятию размерности. Например, разложение тензорного поезда<sup>3</sup>. Существуют разложения и более общего вида, удобно записывающиеся с помощью формализма так называемых тензорных диаграмм.

<sup>3</sup> Ivan V Oseledets. Tensor-train decomposition. *SIAM Journal on Scientific Computing*, 33(5):2295–2317, 2011

Автор благодарит Анну Федорову, которая помогала с подготовкой картинок и набором части тега этой лекции.

### Список литературы

- [1] Tamara G Kolda and Brett W Bader. Tensor decompositions and applications. *SIAM review*, 51(3):455–500, 2009.
- [2] Lieven De Lathauwer, Bart De Moor, and Joos Vandewalle. A multilinear singular value decomposition. *SIAM journal on Matrix Analysis and Applications*, 21(4):1253–1278, 2000.
- [3] Ivan V Oseledets. Tensor-train decomposition. *SIAM Journal on Scientific Computing*, 33(5):2295–2317, 2011.
- [4] Е. Е. Тыртышников. *Матричный анализ и линейная алгебра*. Физматлит, 2007.
- [5] G.H. Golub and C.F. Van Loan. *Matrix Computations, 4th Edition*. The Johns Hopkins University Press, Baltimore, 2013.